

Università degli Studi dell'Insubria
Laurea Triennale in Informatica

Corso: **Interfacce Uomo-Macchina** – a.a. 2025/26

Docente: Prof.ssa Silvia Corchs

Documentazione Tecnica

Pipeline di Preprocessing EEG
per la Classificazione di Decisioni
nell'Iowa Gambling Task

Dataset di riferimento:

Chávez-Sánchez M., Torres-Ramos S., Román-Godínez I., Salido-Ruiz R.A.
*Behavioral and electroencephalographic dataset simultaneously acquired
during the Iowa Gambling Task*
Scientific Data, 13:359, 2026
DOI: [10.1038/s41597-026-06662-0](https://doi.org/10.1038/s41597-026-06662-0)

Dataset disponibile su:

[Mendeley Data – 2pw2m39yct](#), versione 2

Progetto d'esame – Parte I: Preprocessing EEG
Maggio 2026

Indice

1	Introduzione e Obiettivi	3
1.1	Contesto del progetto	3
1.2	Obiettivo della classificazione	3
1.3	Struttura della documentazione	3
2	Dataset	3
2.1	Descrizione generale	3
2.2	Protocollo sperimentale	4
2.3	Iowa Gambling Task – Struttura dei payoff	4
2.4	Struttura dei file	5
2.4.1	Formato EEG.csv	5
2.4.2	Formato IGT.csv	5
2.5	Canali EEG e posizionamento	5
3	Pipeline di Preprocessing EEG	6
3.1	Step 1 – Caricamento e creazione oggetto MNE Raw	6
3.1.1	Caricamento	6
3.1.2	Conversione in MNE RawArray	6
3.2	Step 2 – Re-referencing: Common Average Reference (CAR)	7
3.2.1	Problema del riferimento	7
3.2.2	Common Average Reference	7
3.2.3	Motivazione	7
3.3	Step 3 – Filtraggio Bandpass	8
3.3.1	Motivazione neurofisiologica	8
3.3.2	Specifiche del filtro	8
3.4	Step 4 – Filtraggio Notch	9
3.4.1	Motivazione	9
3.5	Step 5 – Rimozione Artefatti con ICA	9
3.5.1	Il problema degli artefatti EEG	9
3.5.2	Principio dell'ICA	9
3.5.3	Algoritmo: FastICA	10
3.5.4	Identificazione automatica componenti oculari	10
3.6	Step 6 – Normalizzazione Z-Score	11
3.6.1	Motivazione	11
3.6.2	Formula	11
4	Sincronizzazione EEG-IGT	12
4.1	Meccanismo di sincronizzazione	12
4.2	Validazione dei trial	12
4.3	Generazione delle label	12
5	Estrazione delle Epoche	13
5.1	Finestra temporale	13
5.2	Motivazione della finestra pre-decisionale	13
5.3	Output delle epoche	13
6	Output e Formato per Machine Learning	13

6.1	File salvati per soggetto	13
6.2	Caricamento per classificazione	14
6.3	Strategia di validazione raccomandata	14
7	Risultati Ottenuti e Confronto con la Letteratura	15
7.1	Statistiche del dataset preprocessato	15
7.2	Distribuzione delle scelte e confronto con il paper	15
7.3	Confronto con la validazione del paper originale	16
8	Scelte Implementative e Motivazioni	16
8.1	Libreria MNE-Python	16
8.2	Scelta di $K = 15$ componenti ICA	16
8.3	Assenza di baseline correction	17
8.4	Struttura modulare del codice	17
9	Conclusioni e Sviluppi Futuri	17
9.1	Riepilogo	17
9.2	Sviluppi futuri (prossime fasi)	18

1 Introduzione e Obiettivi

1.1 Contesto del progetto

Il presente documento descrive nel dettaglio la pipeline di preprocessing EEG implementata nell'ambito del progetto d'esame del corso di Interfacce Uomo-Macchina. L'obiettivo generale del progetto è sviluppare un sistema capace di **classificare automaticamente le decisioni umane** – distinguendo decisioni *vantaggiose* da decisioni *svantaggiose* – a partire dal segnale elettroencefalografico (EEG) acquisito durante l'esecuzione dell'Iowa Gambling Task (IGT).

Il preprocessing costituisce la **fase fondante** dell'intera pipeline: la qualità del segnale elaborato determina direttamente le performance dei classificatori a valle. Un segnale non correttamente filtrato, non dereferenziato o contaminato da artefatti produce feature spurie che degradano qualsiasi modello di machine learning, indipendentemente dalla sua sofisticazione.

1.2 Obiettivo della classificazione

Task di classificazione

Input: segnale EEG nella finestra temporale $[-2s, 0s]$ prima del momento di decisione.

Output: classe binaria

- **Classe 0** – Decisione *svantaggiosa* (deck A o B)
- **Classe 1** – Decisione *vantaggiosa* (deck C o D)

1.3 Struttura della documentazione

Il documento è organizzato come segue:

1. **Sezione 2:** descrizione del dataset (paper, acquisizione, struttura file)
2. **Sezione 3:** pipeline di preprocessing passo per passo
3. **Sezione 4:** sincronizzazione EEG-IGT e generazione label
4. **Sezione 5:** estrazione delle epoche
5. **Sezione 6:** output e formato dati per ML
6. **Sezione 7:** risultati ottenuti e confronto con la letteratura
7. **Sezione 8:** scelte implementative e motivazioni

2 Dataset

2.1 Descrizione generale

Il dataset utilizzato è stato pubblicato da Chávez-Sánchez et al. (2026) su *Scientific Data* ed è pubblicamente disponibile su Mendeley Data. Contiene registrazioni simultanee di dati comportamentali EEG raccolte durante l'esecuzione dell'Iowa Gambling Task su 59 partecipanti non clinici.

Tabella 1: Caratteristiche principali del dataset

Parametro	Valore
Numero partecipanti	59 (30 M, 29 F)
Età media	21.44 anni ($\sigma = 1.30$)
Gruppi	Engineering (ENG, $n = 29$), Physical Culture and Sports (PCS, $n = 29$)
Dispositivo EEG	Natus XLTEK EEG 32®
Elettrodi attivi	21 (sistema internazionale 10-20)
Riferimento acquisizione	Pz
Elettrodo di terra	CPz
Frequenza di campionamento	256 Hz
Impedenza minima	10 k Ω
Trial IGT per soggetto	200 (2 blocchi da 100)
Durata media sessione	≈ 16 minuti

2.2 Protocollo sperimentale

La sessione sperimentale è strutturata in quattro momenti distinti:

1. **Baseline (3 min):** il partecipante mantiene gli occhi aperti in stato di riposo; il segnale EEG viene registrato come riferimento basale.
2. **Primo blocco IGT (100 decisioni):** il partecipante esegue il task scegliendo tra i deck A, B, C, D.
3. **Pausa (4 min):** periodo di riposo tra i due blocchi.
4. **Secondo blocco IGT (100 decisioni):** completamento del task.

Ogni iterazione del task si compone di due fasi:

- **Pre-decisione:** il partecipante delibera quale deck scegliere (durata variabile, dipendente dal RT individuale).
- **Feedback (1500 ms):** il partecipante visualizza il risultato (crediti vinti/perse).

2.3 Iowa Gambling Task – Struttura dei payoff

L'IGT è stato progettato da Bechara et al. (1994) per valutare il processo decisionale in condizioni di incertezza. I quattro deck hanno strutture di payoff asimmetriche:

Tabella 2: Struttura dei payoff dei deck nell'IGT originale

Deck	Guadagno/carta	Perdita occasionale	Netto ogni 10 carte	Tipo
A	+100	$-\{150, 200, 250, 300, 350\}$	-250	Svantaggioso
B	+100	-1250 (1 volta su 10)	-250	Svantaggioso
C	+50	$-\{25, 50, 75\}$	+250	Vantaggioso
D	+50	-250 (1 volta su 10)	+250	Vantaggioso

I deck A e B producono guadagni immediati elevati ma perdite nette a lungo termine (-250 ogni 10 carte). I deck C e D producono guadagni più modesti ma un bilancio

positivo nel lungo periodo (+250 ogni 10 carte). Un soggetto sano e non impulsivo dovrebbe progressivamente preferire C e D.

2.4 Struttura dei file

Il dataset è organizzato secondo lo standard BIDS (*Brain Imaging Data Structure*):

```

root/
  participants.csv      (demografici: sesso, età, gruppo)
  obstetrics.csv       (dati ostetrici per le partecipanti donne)
  substance_use.csv    (uso di sostanze)
  dataset-description.csv
  s-01/
    EEG.csv            (segnale raw, 21 colonne = canali)
    IGT.csv            (dati comportamentali)
    processed_EEG.csv  (EEG preprocessato dagli autori)
  s-02/
    ...
  s-59/

```

2.4.1 Formato EEG.csv

Matrice di dimensioni ($N_{\text{campioni}} \times 21$), dove ogni colonna corrisponde a un elettrodo. I valori sono in microvolt (μV). Per il soggetto s-01: $N_{\text{campioni}} = 270336$, corrispondente a 1056 secondi (≈ 17.6 minuti) a 256 Hz.

2.4.2 Formato IGT.csv

Ogni riga corrisponde a un trial. Le colonne rilevanti sono:

Tabella 3: Colonne del file IGT.csv

Colonna	Tipo	Descrizione
iteration	int	Numero del trial (1–200)
EEG sample	int	Indice campione EEG sincronizzato con la decisione
decision	str	Deck scelto: A, B, C o D
win	int	Crediti vinti
lose	int	Crediti persi (valore negativo)
balance	int	Bilancio cumulativo

2.5 Canali EEG e posizionamento

I 21 elettrodi attivi, referenziati a Pz durante l’acquisizione, coprono le principali regioni corticali:

Tabella 4: Elettrodi EEG e aree corticali associate

Regione	Elettrodi
Frontale	Fp1, Fp2, Fpz, F3, F4, F7, F8, Fz
Centrale	C3, C4, Cz
Temporale	T4, T5, T6, A1, A2
Parietale	P3, P4, Pz
Occipitale	O1, O2

3 Pipeline di Preprocessing EEG

La pipeline è implementata in Python 3.10+ utilizzando la libreria MNE-Python (versione ≥ 1.6) come framework principale per l'elaborazione EEG. La struttura modulare è organizzata in funzioni indipendenti e componibili.

Panoramica della pipeline

Input: EEG.csv + IGT.csv per ogni soggetto

Step 1: Caricamento e creazione oggetto MNE Raw

Step 2: Re-referencing (Common Average Reference)

Step 3: Filtraggio bandpass 0.5–70 Hz

Step 4: Filtraggio notch 50 Hz

Step 5: Rimozione artefatti via ICA

Step 6: Normalizzazione z-score per canale

Step 7: Sincronizzazione EEG-IGT

Step 8: Estrazione epoche [−2s, 0s]

Step 9: Generazione label e salvataggio

Output: tensori .npy pronti per classificazione ML

3.1 Step 1 – Caricamento e creazione oggetto MNE Raw

3.1.1 Caricamento

Il file EEG.csv viene letto con `pandas.read_csv()` producendo una matrice NumPy di shape $(N_{\text{campioni}}, 21)$. I valori sono in μV come forniti dal dispositivo di acquisizione.

3.1.2 Conversione in MNE RawArray

MNE-Python richiede che i dati siano in **Volt** (non μV) e in formato $(N_{\text{canali}}, N_{\text{campioni}})$ (trasposta rispetto alla convenzione CSV). La conversione è:

Conversione unità di misura

$$\mathbf{X}_{\text{MNE}} = \mathbf{X}_{\text{CSV}}^{\top} \times 10^{-6} \quad [\text{shape} : (21, N_{\text{campioni}})]$$

Viene poi creato un oggetto `mne.Info` contenente i metadati:

- nomi dei canali (`ch_names`): lista dei 21 elettrodi
- frequenza di campionamento: `sfreq = 256` Hz

- tipo di canale: eeg

Listing 1: Creazione oggetto MNE Raw

```

1 data_v = eeg_data.T * 1e-6      # (21, N_campioni), in Volt
2 info = mne.create_info(ch_names=CH_NAMES, sfreq=256, ch_types
   = "eeg")
3 raw = mne.io.RawArray(data_v, info)

```

3.2 Step 2 – Re-referencing: Common Average Reference (CAR)

3.2.1 Problema del riferimento

Il segnale EEG è sempre misurato come **differenza di potenziale** tra un elettrodo attivo e un elettrodo di riferimento. Il dataset è stato acquisito con riferimento a **Pz**. Tuttavia, ogni scelta di riferimento introduce un bias: il potenziale di Pz viene sottratto da tutti i canali, potendo contaminare o mascherare attività locali.

3.2.2 Common Average Reference

Il *Common Average Reference* (CAR) ri-referenzia ogni canale rispetto alla media istantanea di tutti gli elettrodi:

Common Average Reference

$$x_i^{\text{CAR}}(t) = x_i(t) - \frac{1}{N} \sum_{j=1}^N x_j(t) \quad \forall i = 1, \dots, N$$

dove $N = 21$ è il numero di canali e $x_i(t)$ è il segnale del canale i al tempo t .

3.2.3 Motivazione

- **Riduzione artefatti comuni:** rumori presenti su tutti gli elettrodi (es. vibrazioni, campo elettrico ambientale) vengono cancellati dalla sottrazione della media.
- **Indipendenza dal sito di riferimento:** il CAR è la scelta standard nella letteratura ERP e nella classificazione EEG-based [5].
- **Presupposto:** con 21 canali distribuiti uniformemente sul cuoio capelluto, la somma dei potenziali tende a zero (approssimazione sferica). Con pochi elettrodi questo assunto è meno valido, ma rimane la scelta più robusta disponibile.

Listing 2: Applicazione CAR in MNE

```

1 raw_ref, _ = mne.set_eeg_reference(raw, ref_channels="average
   ",
2                                     copy=True)

```


3.3 Step 3 – Filtraggio Bandpass

3.3.1 Motivazione neurofisiologica

Il segnale EEG grezzo contiene componenti indesiderate a frequenze molto basse (deriva DC, movimenti lenti) e molto alte (rumore elettronico, EMG). Le bande neurofisiologicamente rilevanti per il task decisionale sono:

Tabella 5: Bande di frequenza EEG e ruolo nel task decisionale

Banda	Range (Hz)	Elettrodi chiave	Rilevanza IGT
Delta (δ)	1–4	Frontale, Parietale	Processi decisionali lenti, attenzione sostenuta
Theta (θ)	4–8	Fz, F3, F4	Working memory, controllo cognitivo, monitoraggio errori
Alpha (α)	8–13	O1, O2, P3, P4	Inibizione cognitiva, resting state
Beta (β)	13–30	Frontale, Centrale	Elaborazione sensoriale, preparazione motoria
Gamma (γ)	30–70	Distribuito	Binding cognitivo, integrazione informazioni

La banda theta frontale è particolarmente rilevante: Cui et al. (2013) dimostrano che l'attività theta in Fz aumenta significativamente durante la fase pre-decisionale nell'IGT, riflettendo il carico della working memory e il monitoraggio del rischio.

3.3.2 Specifiche del filtro

Parametri filtro bandpass

$$f_{\text{low}} = 0.5 \text{ Hz} \quad f_{\text{high}} = 70 \text{ Hz}$$

Tipo: FIR (Finite Impulse Response), finestra di Hamming

Implementazione: `MNE raw.filter(l_freq=0.5, h_freq=70)`

Perché FIR e non IIR? Il paper originale usa un filtro IIR (Butterworth) di 6° ordine. La scelta del filtro FIR nella nostra implementazione è motivata da:

- **Fase lineare:** i filtri FIR con simmetria hanno risposta di fase lineare, preservando la forma temporale dei transienti ERP – fondamentale per l'analisi delle componenti evento-correlate.
- **Stabilità garantita:** i filtri FIR sono intrinsecamente stabili, a differenza degli IIR.
- **Standard de facto MNE:** la documentazione MNE raccomanda FIR per preprocessing EEG.

Taglio basso a 0.5 Hz: rimuove la deriva DC e le fluttuazioni lente (respirazione ≈ 0.2 Hz) mantenendo le componenti delta rilevanti.

Taglio alto a 70 Hz: il paper usa 70 Hz come limite superiore, preservando tutta l'attività corticale rilevante. L'attività muscolare (EMG) è predominante sopra 80–100 Hz.

Listing 3: Filtro bandpass FIR

```
1 raw.filter(l_freq=0.5, h_freq=70.0,  
2           method="fir", fir_window="hamming")
```

3.4 Step 4 – Filtraggio Notch

3.4.1 Motivazione

La rete elettrica introduce un'interferenza sinusoidale alla frequenza di 50 Hz (standard europeo) o 60 Hz (standard nordamericano/messicano). Questa componente non ha origine neurale e deve essere rimossa.

Nota sul dataset

Il dataset è stato acquisito in Messico (Universidad de Guadalajara), dove la rete elettrica opera a **60 Hz**. Tuttavia, avendo impostato il notch a **50 Hz** (standard europeo), è opportuno verificare il segnale PSD del dataset reale. Se si osserva un picco residuo a 60 Hz dopo il preprocessing, il parametro NOTCH_FREQ va modificato da 50 a 60 nel file `eeg_preprocessing.py`.

Listing 4: Filtro notch

```
1 raw.notch_filter(freqs=50.0, method="fir")  
2 # Per dataset messicano: sostituire con freqs=60.0
```

3.5 Step 5 – Rimozione Artefatti con ICA

3.5.1 Il problema degli artefatti EEG

Il segnale EEG registrato al cuoio capelluto è una sovrapposizione di:

- **Attività neurale:** la componente di interesse
- **Artefatti oculari (EOG):** blink ($\approx 100\text{--}200\ \mu\text{V}$) e movimenti oculari, dominanti sui canali frontali Fp1, Fp2, Fpz
- **Artefatti muscolari (EMG):** contrazioni muscolari, predominanti ad alte frequenze ($> 30\ \text{Hz}$)
- **Artefatti cardiaci (ECG):** battito cardiaco, visibile come picco periodico

L'ampiezza degli artefatti da blink ($100\text{--}200\ \mu\text{V}$) è spesso **10–20 volte** superiore all'ampiezza del segnale EEG corticale ($5\text{--}20\ \mu\text{V}$), rendendoli la principale fonte di inquinamento del segnale.

3.5.2 Principio dell'ICA

L'Independent Component Analysis (ICA) è un metodo di separazione cieca delle sorgenti (*Blind Source Separation*). Il modello assunto è:

Modello ICA

$$\mathbf{X} = \mathbf{A} \mathbf{S}$$

dove:

- $\mathbf{X} \in \mathbb{R}^{N_{\text{ch}} \times T}$ = segnale EEG osservato (21 canali, T campioni)
- $\mathbf{S} \in \mathbb{R}^{K \times T}$ = sorgenti indipendenti latenti (K componenti)
- $\mathbf{A} \in \mathbb{R}^{N_{\text{ch}} \times K}$ = matrice di miscelazione (mixing matrix)

L'ICA stima $\mathbf{W} = \mathbf{A}^{-1}$ (unmixing matrix) massimizzando la non-gaussianità delle componenti.

La ricostruzione del segnale pulito avviene azzerando le righe di $\mathbf{S}$ corrispondenti agli artefatti:

$$\hat{\mathbf{X}} = \mathbf{A}_{\text{rid}} \mathbf{S}_{\text{rid}}$$

dove il pedice “rid” indica la versione ridotta senza le componenti artefattuali.

3.5.3 Algoritmo: FastICA

Viene utilizzato l'algoritmo FastICA, che massimizza la non-gaussianità tramite la funzione di contrasto:

$$G(u) = \log \cosh(u)$$

I parametri utilizzati sono:

- **Componenti:** $K = 15$ (con 21 canali, 15 componenti catturano la maggior parte della varianza)
- **Iterazioni massime:** 1500
- **Tolleranza di convergenza:** 10^{-4}
- **Random state:** 42 (riproducibilità)

3.5.4 Identificazione automatica componenti oculari

Le componenti artefattuali vengono identificate automaticamente tramite correlazione con i canali EOG frontali (Fp1, Fp2, Fpz):

Listing 5: Identificazione e rimozione componenti EOG

```

1 eog_channels = ["Fp1", "Fp2", "Fpz"]
2 eog_indices, eog_scores = ica.find_bads_eog(
3     raw, ch_name=eog_channels, threshold=3.0
4 )
5 ica.exclude = eog_indices
6 ica.apply(raw_clean)
```

Il parametro `threshold=3.0` indica che vengono escluse le componenti la cui correlazione con il canale EOG supera 3 deviazioni standard rispetto alla distribuzione delle correlazioni. Per il soggetto s-01, le componenti 0 e 1 sono state identificate come artefatti oculari e rimosse.

Nota implementativa – Pre-filtraggio per ICA

L'ICA viene fittata su una copia del segnale pre-filtrata con taglio basso a 1 Hz (invece di 0.5 Hz). Questo è raccomandato dalla documentazione MNE: la deriva lenta sotto 1 Hz può compromettere la stima delle componenti indipendenti.

3.6 Step 6 – Normalizzazione Z-Score

3.6.1 Motivazione

L'ampiezza del segnale EEG varia considerevolmente tra soggetti diversi (variabilità inter-soggetto). Le cause principali sono:

- Diverso spessore del cuoio capelluto e del cranio
- Diversa impedenza degli elettrodi
- Differenze individuali nell'attività cerebrale di base

Senza normalizzazione, un classificatore addestrato su più soggetti tende a imparare le differenze di ampiezza individuali piuttosto che i pattern decisionali.

3.6.2 Formula

Normalizzazione Z-Score per canale

$$z_i(t) = \frac{x_i(t) - \mu_i}{\sigma_i}$$

dove, per ogni canale i :

$$\mu_i = \frac{1}{T} \sum_{t=1}^T x_i(t) \quad \sigma_i = \sqrt{\frac{1}{T} \sum_{t=1}^T (x_i(t) - \mu_i)^2}$$

Il risultato ha media zero e deviazione standard unitaria **per ogni canale**.

La normalizzazione è applicata sull'intera registrazione (non sulle singole epoche) per preservare la struttura temporale relativa del segnale.

Listing 6: Normalizzazione z-score per canale

```

1 data = raw.get_data() # (21, N_campioni)
2 mu    = data.mean(axis=1, keepdims=True)
3 sigma = data.std(axis=1, keepdims=True)
4 sigma[sigma < 1e-10] = 1e-10 # evita divisione per zero
5 raw._data = (data - mu) / sigma

```

4 Sincronizzazione EEG–IGT

4.1 Meccanismo di sincronizzazione

Il file IGT.csv contiene la colonna `EEG sample` che specifica l'indice esatto del campione EEG corrispondente al momento in cui il partecipante ha effettuato la scelta del deck. Questa colonna è stata registrata in tempo reale durante l'esperimento, garantendo una sincronizzazione precisa a livello di campione.

La conversione in unità di tempo è:

Conversione campione – tempo

$$t_{\text{decisione}}^{(k)} = \frac{\text{EEG_SAMPLE}^{(k)}}{f_s} = \frac{\text{EEG_SAMPLE}^{(k)}}{256} \quad [\text{secondi}]$$

dove $k = 1, \dots, 200$ indica il trial.

4.2 Validazione dei trial

Un trial è considerato **valido** per l'estrazione dell'epoca se l'intera finestra temporale $[-2s, 0s]$ ricade all'interno della registrazione EEG disponibile:

$$\text{VALID}^{(k)} = \begin{cases} \text{True} & \text{se } \text{EEG_SAMPLE}^{(k)} \geq 2 \cdot f_s = 512 \\ \text{False} & \text{altrimenti} \end{cases}$$

Nel dataset reale tutti i 200 trial per soggetto risultano validi, poiché la baseline iniziale di 3 minuti garantisce un ampio margine prima del primo trial IGT.

4.3 Generazione delle label

Le label binarie vengono assegnate automaticamente in base al deck scelto:

Mapping deck – label

$$\text{label}^{(k)} = \begin{cases} 0 & \text{se } \text{deck}^{(k)} \in \{A, B\} \quad (\text{disadvantageous}) \\ 1 & \text{se } \text{deck}^{(k)} \in \{C, D\} \quad (\text{advantageous}) \end{cases}$$

Motivazione neuroscientifica: la distinzione A/B vs C/D riflette la dicotomia fondamentale dell'IGT: scelte guidate dalla ricompensa immediata (A/B) vs scelte guidate dall'ottimizzazione a lungo termine (C/D). Questa distinzione è supportata da differenze nell'attivazione prefrontale documentate tramite EEG, fMRI e skin conductance response.

5 Estrazione delle Epoche

5.1 Finestra temporale

Definizione epoca

Per ogni trial k , l'epoca EEG è definita come:

$$\mathcal{E}^{(k)} = \mathbf{X} \left[\text{EEG_SAMPLE}^{(k)} - 2f_s : \text{EEG_SAMPLE}^{(k)} \right]$$

$$\text{shape: } (21 \text{ canali}, 2\text{s} \times 256 \text{ Hz}) = (21, 512)$$

In MNE, la finestra viene definita come $[\text{tmin} = -2\text{s}, \text{tmax} = 0\text{s}]$.

MNE include il campione corrispondente a $t = 0$ nella finestra, producendo 513 campioni effettivi ($512 + 1$) per ogni epoca.

5.2 Motivazione della finestra pre-decisionale

La scelta della finestra $[-2\text{s}, 0\text{s}]$ è motivata da evidenze neuroscientifiche sulla temporalità dei processi decisionali:

- **Decision Preceding Negativity (DPN):** Bianchin e Angrilli (2011) identificano una negatività frontale in Fz che inizia circa 500 ms prima della decisione nell'IGT, riflettendo il processo di valutazione del rischio.
- **Slow Cortical Potentials (SCP):** I potenziali corticali lenti si sviluppano su scale temporali di 1–2 secondi, richiedendo una finestra ampia per essere catturati.
- **Attività theta frontale:** L'oscillazione theta (4–8 Hz) in Fz è massima durante la deliberazione, tipicamente nei 1.5–2 secondi che precedono la scelta.
- **Compatibilità con il paradigma:** La finestra non include il feedback (che arriva dopo $t = 0$), evitando la contaminazione con componenti post-decisionali come FRN e P300.

5.3 Output delle epoche

Il risultato finale per ogni soggetto è un tensore tridimensionale:

Shape del tensore epoche

$$\mathbf{X}_{\text{subj}} \in \mathbb{R}^{N_{\text{trial}} \times N_{\text{ch}} \times N_t} = \mathbb{R}^{200 \times 21 \times 513}$$

$$\mathbf{y}_{\text{subj}} \in \{0, 1\}^{N_{\text{trial}}} = \{0, 1\}^{200}$$

6 Output e Formato per Machine Learning

6.1 File salvati per soggetto

Per ogni soggetto vengono salvati quattro file:

Tabella 6: File di output per soggetto

File	Shape	Contenuto
s-XX_epochs.npy	(200, 21, 513)	Segnale EEG normalizzato per ogni trial
s-XX_labels.npy	(200,)	Label binarie (0=disadv, 1=adv)
s-XX_samples.npy	(200,)	Indici campione EEG originali
s-XX_info.npz	–	Metadati: ch_names, sfreq, tmin, tmax

6.2 Caricamento per classificazione

Listing 7: Caricamento del dataset completo per ML

```

1 import numpy as np
2 from pathlib import Path
3
4 epochs_dir = Path('./output/epochs')
5
6 all_X, all_y, all_subjects = [], [], []
7 for label_file in sorted(epochs_dir.glob('*_labels.npy')):
8     sid = label_file.stem.replace('_labels', '')
9     X_s = np.load(epochs_dir / f'{sid}_epochs.npy') # (200,
10     y_s = np.load(label_file) #
11     (200,)
12     all_X.append(X_s)
13     all_y.append(y_s)
14     all_subjects.extend([sid] * len(y_s))
15
16 X = np.concatenate(all_X, axis=0) # (N_tot, 21, 513)
17 y = np.concatenate(all_y, axis=0) # (N_tot,)
18 subjects = np.array(all_subjects) # per LOSO cross-
19     validation

```

6.3 Strategia di validazione raccomandata

Leave-One-Subject-Out (LOSO)

I dati fisiologici sono **strettamente soggetto-dipendenti**: ogni individuo ha pattern EEG unici legati alla morfologia del cranio, all'attività basale e agli stili cognitivi. Una divisione random train/test che mescola trial dello stesso soggetto produce una stima **ottimisticamente distorta** delle performance (data leakage inter-soggetto).

La strategia corretta è la **Leave-One-Subject-Out (LOSO) cross-validation**: ad ogni fold, il modello viene addestrato su $N - 1$ soggetti e testato sul soggetto escluso. Questo stima la capacità di **generalizzazione a nuovi individui**.

Listing 8: LOSO cross-validation con scikit-learn

```

1 from sklearn.model_selection import LeaveOneGroupOut

```

```

2
3 logo = LeaveOneGroupOut()
4 for train_idx, test_idx in logo.split(X, y, groups=subjects):
5     X_train, X_test = X[train_idx], X[test_idx]
6     y_train, y_test = y[train_idx], y[test_idx]
7     # ... addestra classificatore su X_train, y_train
8     # ... valuta su X_test, y_test

```

7 Risultati Ottenuti e Confronto con la Letteratura

7.1 Statistiche del dataset preprocessato

La pipeline è stata eseguita su 55 soggetti (su 59 totali; 4 cartelle risultano mancanti nel dataset scaricato). I risultati sono riassunti nella tabella seguente:

Tabella 7: Statistiche aggregate del dataset preprocessato

Parametro	Valore
Soggetti elaborati	55/59
Trial totali	$55 \times 200 = 11.000$
Epoche per soggetto	200 (100% dei trial, tutti validi)
Shape tensore per soggetto	(200, 21, 513)
Trial advantageous (media)	≈ 101 (50.5%)
Trial disadvantageous (media)	≈ 99 (49.5%)
Durata media registrazione	≈ 1056 s (≈ 17.6 min)
Componenti ICA rimosse (s-01)	2 (componenti 0 e 1)

7.2 Distribuzione delle scelte e confronto con il paper

Il paper (Fig. 7) mostra che i partecipanti tendono inizialmente a scegliere deck svantaggiosi (A/B) e progressivamente imparano a preferire quelli vantaggiosi (C/D), in accordo con il modello di apprendimento somatic marker di Bechara.

I dati ottenuti mostrano un'ampia variabilità inter-soggetto nella distribuzione delle scelte:

- **Apprendimento rapido:** soggetti s-51 (167/33), s-27 (159/41), s-17 (160/40) – scelta prevalentemente vantaggiosa.
- **Apprendimento lento o assente:** soggetti s-36 (59/141), s-13 (62/138), s-03 (66/134) – scelta prevalentemente svantaggiosa.
- **Distribuzione bilanciata:** maggioranza dei soggetti con proporzioni prossime a 50/50.

Questa variabilità è **pienamente in linea** con la letteratura IGT: Steingroever et al. (2013) riportano che una quota significativa di partecipanti sani non sviluppa la preferenza per C/D entro 200 trial.

7.3 Confronto con la validazione del paper originale

Il paper effettua una validazione del segnale EEG tramite Power Spectral Density (PSD) e analisi ERP:

Tabella 8: Confronto validazione EEG: paper vs pipeline implementata

Aspetto	Paper originale	Pipeline implementata
Filtraggio	IIR 6° ordine, 0.5–70 Hz, notch 60 Hz	FIR Hamming, 0.5–70 Hz, notch 50 Hz
Riferimento	Auricolari (A1+A2)/2 per ERP	CAR (Common Average Reference)
Rimozione artefatti	Non applicata nella validazione	ICA FastICA, 15 componenti
Normalizzazione	Non applicata	Z-score per canale
Finestra analisi	200 finestre da 4s ($\pm 2s$)	[-2s, 0s] pre-decisione
Componenti ERP	FRN, P300, N400 identificate	Non analizzate (fase futura)

Nota sul notch filter

Il dataset è stato acquisito in Messico, dove la rete elettrica opera a **60 Hz**. La pipeline implementata usa 50 Hz (standard europeo). Si raccomanda di verificare la PSD del segnale preprocessato e, se presente un picco residuo a 60 Hz, modificare `NOTCH_FREQ = 60.0` nel codice.

8 Scelte Implementative e Motivazioni

8.1 Libreria MNE-Python

MNE-Python è stata scelta come framework principale per i seguenti motivi:

- **Standard industriale:** libreria di riferimento per l'analisi EEG/MEG in Python, con oltre 1000 citazioni scientifiche.
- **Gestione completa del dato:** fornisce strutture dati (Raw, Epochs, Evoked) che gestiscono automaticamente metadati, canali e timing.
- **Algoritmi validati:** implementazioni di filtri, ICA, ERP testate dalla comunità scientifica.
- **Integrazione con scikit-learn:** gli array NumPy prodotti da MNE sono direttamente compatibili con la pipeline ML.

8.2 Scelta di $K = 15$ componenti ICA

Con 21 canali disponibili, il numero teorico massimo di componenti indipendenti è 21. La scelta di $K = 15$ è un compromesso:

- **Cattura la varianza principale:** 15 componenti tipicamente spiegano $> 95\%$ della varianza del segnale.
- **Riduce il rischio di overfitting:** con più componenti, l'ICA ha più difficoltà a convergere e tende a frammentare sorgenti genuine.
- **Accelera il calcolo:** la complessità di FastICA è $O(K^2 \cdot T)$.

8.3 Assenza di baseline correction

La baseline correction (sottrazione della media in una finestra pre-stimolo) è comune nell'analisi ERP ma **non è applicata** in questa pipeline. La motivazione è:

- La finestra $[-2s, 0s]$ è interamente pre-decisionale: non esiste una finestra “pre-stimolo” su cui calcolare la baseline.
- La normalizzazione z-score sull'intera registrazione svolge una funzione analoga, rimuovendo il livello DC per canale.
- Per l'analisi ERP classica (es. replicare i risultati del paper), la baseline correction andrebbe applicata sulla finestra post-feedback $[0s, +2s]$.

8.4 Struttura modulare del codice

Il codice è organizzato in funzioni indipendenti per garantire:

- **Manutenibilità:** ogni step può essere modificato senza impattare gli altri.
- **Testabilità:** ogni funzione può essere testata in isolamento con dati sintetici.
- **Riutilizzabilità:** le funzioni sono importabili da notebook Jupyter per analisi interattive.
- **Integrabilità:** l'output in formato NumPy è direttamente compatibile con scikit-learn, PyTorch, TensorFlow.

9 Conclusioni e Sviluppi Futuri

9.1 Riepilogo

La pipeline implementata esegue in modo completamente automatizzato l'intero preprocessing EEG dal segnale grezzo alle epoche pronte per la classificazione. I punti chiave sono:

1. **Filtraggio robusto:** bandpass FIR 0.5–70 Hz + notch preserva tutte le bande neurofisiologicamente rilevanti.
2. **Re-referencing CAR:** riduce la dipendenza dal sito di riferimento e gli artefatti comuni.
3. **ICA automatica:** rimozione oggettiva degli artefatti oculari senza intervento manuale.
4. **Normalizzazione:** z-score per canale riduce la variabilità inter-soggetto.

5. **Sincronizzazione precisa:** uso della colonna EEG_SAMPLE garantisce allineamento campione-per-campione.
6. **Output standard:** formato NumPy compatibile con qualsiasi framework ML.

9.2 Sviluppi futuri (prossime fasi)

- **Feature extraction:** calcolo di feature nel dominio del tempo (ampiezza ERP), della frequenza (potenza per banda) e tempo-frequenza (wavelet, Hilbert).
- **Classificazione:** confronto tra SVM, Random Forest, LDA e reti neurali (CNN, LSTM) con cross-validazione LOSO.
- **Replicazione risultati paper:** analisi ERP (FRN, P300, N400) per confronto diretto con la Fig. 9 del paper originale.
- **Sensor fusion:** analisi del contributo relativo di sottoinsiemi di canali (es. solo frontali vs tutti i canali).

Riferimenti bibliografici

- [1] Chávez-Sánchez M., Torres-Ramos S., Román-Godínez I., Salido-Ruiz R.A. *Behavioral and electroencephalographic dataset simultaneously acquired during the Iowa Gambling Task*. Scientific Data, 13:359, 2026. DOI: [10.1038/s41597-026-06662-0](https://doi.org/10.1038/s41597-026-06662-0)
- [2] Bechara A., Damasio A.R., Damasio H., Anderson S.W. *Insensitivity to future consequences following damage to human prefrontal cortex*. Cognition, 50:7–15, 1994.
- [3] Cui J.F., Chen Y.H., Wang Y., Shum D.H., Chan R.C. *Neural correlates of uncertain decision making: ERP evidence from the Iowa Gambling Task*. Frontiers in Human Neuroscience, 7:776, 2013.
- [4] Bianchin M., Angrilli A. *Decision preceding negativity in the Iowa Gambling Task: an ERP study*. Brain and Cognition, 75:273–280, 2011.
- [5] Nunez P.L. et al. *A theoretical and experimental study of high resolution EEG based on surface Laplacians and cortical imaging*. Electroencephalography and Clinical Neurophysiology, 90:40–57, 1994.
- [6] Gramfort A. et al. *MEG and EEG data analysis with MNE-Python*. Frontiers in Neuroscience, 7:267, 2013.
- [7] Steingroever H. et al. *Performance of healthy participants on the Iowa Gambling Task*. Psychological Assessment, 25:180, 2013.
- [8] Kóbor A. et al. *Different strategies underlying uncertain decision making: Higher executive performance is associated with enhanced feedback-related negativity*. Psychophysiology, 52:367–377, 2015.